Liga Acadêmica de Engenharia de Dados (LED) - ELT para base pública de corridas de táxi em Nova York

Equipe 2: Arthur Campos, Davi Rosendo, Heloisa Leite, João Motta, Pedro Casé

1. Dimensionamento:

- Fato_Corrida - Como cada corrida possui elementos e métricas distintas, foi estabelecido que cada linha da fato representa apenas uma corrida, contém as surrogate keys das demais dimensões e métricas da corrida como: número de passageiros, preço, etc.
- Dim_Data: Granularidade - Cada linha representa um dia no calendário, contém informações sobre dia da semana, mês, dia, ano e se é ou não final de semana
- Dim_Horario - Cada linha representa um segundo do dia, contém informações sobre hora, minuto e segundo, além da faixa de horário representada que o horário se encontra
- Dim_Local - Cada linha representa uma zona da cidade de Nova Iorque, contém bairro, zona e o serviço que toma conta da zona
- Dim_Pagamento - Cada linha representa um tipo de pagamento, contém apenas o pagamento|id equivalente em extenso
- Dim_Vendedor - Cada linha representa uma companhia de taxi
- Dim_Ratecode - Cada linha representa um tipo de cobrança de tarifa
- Surrogate Keys (Data e Horário): Criadas sequencialmente (um ID para cada dia e um para cada segundo) para evitar variações de formato de datas/horas e otimizar a performance analítica das junções no banco.
- Natural Keys (Demais Dimensões): Mantidas conforme a origem. A documentação do dataset já define identificadores inteiros, únicos e de baixa cardinalidade (ex: IDs de Zonas e Pagamento), tornando desnecessária a criação de chaves artificiais.

2. Perfilamento:

O perfilamento foi realizado primariamente utilizando o summarize do Duckdb, conseguindo informações sobre nulidade e edge values, também foi utilizado alguns scripts em SQL para a restrição de alguns casos, como: relação nulidade e tipo de pagamento, verificação de corridas que terminam antes do início, etc. Os códigos utilizados para perfilamento estão disponíveis no repositório do projeto.

- Anomalias de valores negativos:
    - Financeiros: fare: 1.26%, extra: 0.59%, mta: 1.16%, gorjeta: 0.0034%, pedagios: 0.068%, improvement: 1.19%, total: 1.19%, congestionamento: 0.92%, aeroporto: 0.16%
    - Hipótese: Possivelmente houve erro de digitação por parte do autor, possível solução: usar o valor absoluto quando a corrida não tiver payment_type = 4, ou seja, a corrida ocorreu bem e não foi contestada
- Anomalias de valores nulos:
    - Colunas: passageiros: 4.7%, RatecodeID: 4.7%, store_and_fwd_flag: 4.7%, congestion_surcharge: 4.7%, Airport_fee: 4.7%
    - Hipótese: Todos os elementos nulos ocorrem quando o pagamento é por uma tarifa dinâmica, usual de aplicativos de transporte, isso indica que, provavelmente, todas as taxas extras variáveis já estão inclusas no valor final, a correção disso ocorre diferentemente para cada coluna afetada.
- Anomalias temporais:
    - Há a existência de linhas de anos anteriores ao do dataset
    - Há a existência de 56 linhas que possuem tempo de início posterior ao término da corrida
    - Há a existência de corridas com duração de dias, incompatíveis com a distância e tarifa cobrada
- Elementos para estatística:
    - Passageiros: min 0 | max 9 | moda 1
    - Distância: Mediana: 1.68
    - Preços: fare mediana $12.80 e gorjeta $2.70
    - Elementos com baixa frequência: Pelo menos 75% sem pedágio e 90% sem taxa de aeroporto
    - Anomalias: Diversas colunas apresentam máximos e mínimos absurdos que serão tratados posteriormente nas próximas etapas, como milhagem absurdas(300k milhas) ou até mesmo milhagens zeradas
- Elementos de distância:
    - Corridas com valores muito altos ou muito baixos, variando de 0.1 milhas a 300k de milhas, quando temos cerca de 95% das corridas dentro da faixa 0-13.7 milhas

Descrição dos Processos de Transformação Aplicados:

- Ajuste de valores negativos: Executamos uma multiplicação por -1 nas métricas financeiras de corridas não contestadas, a fim de normalizar seus valores
- Tratamentos de nulos: Foi observado que todos os valores nulos ocorrem apenas quando o tipo de pagamento é “Flex Fare Trip” (payment_type = 0), que remete ao preço dinâmico de corridas por aplicativo. Nesse tipo de corrida, o taxímetro físico é ignorado, gerando valores ausentes nestas colunas:

    - Passenger_count: Como a contagem de passageiros é amplamente utilizada para pegar métricas relevantes a decisões futuras, foi estabelecido que os valores permanecerão nulos, a fim de não enviesar as consultas.
    - RatecodeID: Preenchemos com 99 que é o código para corridas de rate não informadas ou desconhecidas
    - Store_and_fwd: Normalizado com 'N', pois assume-se que foi enviada ao servidor(e quase 100% do database tem seu store_and_fwd como N)
    - Taxas de aeroporto e congestionamento: Definimos o valor padrão como 0.0, pois imputamos que estão incluídas no valor da "fare" dinâmica
- Temporal:
    - Separação da data em diversos campos
    - Criação de faixa temporal no banco
    - Indicador de final de semana
    - Criação da coluna com o dia da semana escrito
    - Assumimos as datas invertidas como erro do registro manual no sistema, os valores foram invertidos usando a função LEAST() para pegar início real e GREATEST() para pegar o valor de término, assim, garantimos a integridade dos dados da corrida.
    - Corridas com duração superior a um dia tiveram seus campos de data e hora convertidos em nulos, pois não é possível determinar seus horários reais de início e término. Optamos por essa abordagem porque as demais métricas da corrida permanecem confiáveis, evitando assim a exclusão de dados válidos.
    - Exclusão de corridas fora da faixa temporal da pesquisa
- Distância:
    - Quando temos uma corrida com uma disparidade muito grande em relação à nossa base, calculamos a distância verdadeira a partir da tarifa paga por milha pelo usuário, que é equivalente a $3.5 por milha. Não utilizamos o desvio padrão e média de corridas como base para os outliers devido à inflação dessas medidas por base de valores impossíveis. A fórmula consiste no (valor da tarifa - 3.00(bandeirada))/3.50(valor por milha)
- Filtro de inconsistências:
    - Remoção de corridas que tenham 0 milhas rodadas(rever isso para se adequar a um tratamento melhor)
    - Remoção de corridas que ocorreram em um período não pertencente ao dataset. Foram incluídas viagens nas fronteiras do mês (Dezembro/Janeiro e Janeiro/Fevereiro), garantindo que corridas operadas ou finalizadas em janeiro de 2024 não sejam omitidas.
    - Como não temos como definir uma distância e um valor real para as corridas com milhagem e tarifa zeradas, essas linhas foram excluídas a fim de garantir uma análise melhor dos dados. Além disso, também excluímos as corridas que não ultrapassaram o valor mínimo de 3.00, já que esse preço corresponde apenas à bandeirada.

- Mudanças e dúvidas no processo:
    - Originalmente preenchemos os nulos com um valor default definido como 1, por se tratar da moda observada no dataset e por não haver a possibilidade de ter corridas com 0 passageiros, dado à falta de registros de corridas dessa forma, mas foi observado que essa imputação ocasiona uma inflação artificial dos dados do dataset, gerando insights enviesados
- As linhas removidas no tratamento, foram colocadas de forma bruta numa tabela de excluídos, a fim de garantir a rastreabilidade e recuperação do database original, além disso, o tratamento dos dados foi feito utilizando uma View, ou seja, não houve de fato uma alteração física dos dados

3. Insights:

O projeto permite extrair informações estratégicas sobre as corridas de táxi por meio de análises financeiras, geográficas, temporais e operacionais. Os resultados obtidos apoiam a identificação de padrões de demanda, oportunidades de otimização da frota, comportamento das tarifas e fatores que influenciam o faturamento.

Uso de LLMs:

- O principal uso de LLMs por parte da equipe foi como revisor textual da documentação, e para gerar as instruções do repositório (README). Além da explicação de algumas funções próprias do SQL como, por exemplo, o DATEDIFF, utilizado para filtrar corridas com duração maior que o definido.